

Introduction au Machine Learning

Apprentissage Automatique


Meyssem Bouzaïen

Année universitaire: 2025 - 2026

Plan

- 1 Qu'est-ce que le Machine Learning ?
- 2 Le Processus Machine Learning
- 3 Types d'Apprentissage
- 4 Concepts Clés du ML
- 5 Exemples Pratiques
- 6 Outils et Écosystème ML
- 7 Bonnes Pratiques et Conseils
- 8 Conclusion

Rappel : IA vs Machine Learning



Position du ML Le Machine Learning est la branche de l'IA qui permet aux machines d'apprendre à partir des données

Qu'est-ce que le Machine Learning ?

Definition (Machine Learning)

Le Machine Learning est l'étude d'algorithmes informatiques qui s'améliorent automatiquement grâce à l'expérience et l'utilisation de données.

Approche Traditionnelle


- Programmeur écrit les règles
- Logique explicite
- Difficile pour tâches complexes
- Exemple : if-then-else

Approche Machine Learning


- Machine apprend les règles
- Apprentissage par données
- Adapté aux tâches complexes
- Exemple : reconnaissance d'images

Programmation Classique vs Machine Learning

Programmation Classique Machine Learning



Programmeur écrit les règles



Machine découvre les règles

Pourquoi le Machine Learning ?

Problèmes difficiles à programmer

Certaines tâches sont trop complexes pour être programmées avec des règles explicites


Exemples de tâches ML

- Reconnaissance faciale
- Filtrage de spam
- Traduction automatique
- Prédiction de prix
- Recommandation de produits
- Diagnostic médical

Pourquoi c'est difficile ?

- Trop de variables
- Patterns complexes
- Règles non évidentes
- Évolution des données
- Cas particuliers nombreux
- Contexte important

Le Pipeline Machine Learning



Processus itératif

Le ML est un cycle : on revient souvent aux étapes précédentes pour améliorer le modèle

Étape 1 : Les Données - Le Carburant du ML

Principe fondamental

Pas de données = Pas de Machine Learning

Types de données : Structurées (tableaux), Non structurées (texte, images), Temporelles (séries), Mixtes

Sources de données : Bases de données, Fichiers (CSV, JSON), APIs, Web scraping, Capteurs IoT

Qualité des données : Complétude, Exactitude, Cohérence, Pertinence

Règle d'or

Garbage In, Garbage Out — Données de mauvaise qualité → Modèle de mauvaise qualité

Étape 2 : Préparation des Données (1/2)

Nettoyage des données

Étape cruciale qui peut prendre 60-80% du temps du projet ML !

Opérations principales :

① Gestion des valeurs manquantes

- Suppression des lignes
- Imputation (moyenne, médiane, mode)
- Prédiction des valeurs manquantes

② Gestion des outliers (valeurs aberrantes)

- Détection statistique
- Suppression ou correction

③ Gestion des duplicatas

- Identification
- Suppression

Étape 2 : Préparation des Données (2/2)

Transformations :

4 Normalisation / Standardisation

- Mettre les variables à la même échelle
- Exemple : ramener toutes les valeurs entre 0 et 1

5 Encodage des variables catégorielles

- Transformer le texte en nombres
- Exemple : Homme $\rightarrow$ 0, Femme $\rightarrow$ 1

6 Feature Engineering

- Créer de nouvelles variables
- Combiner des variables existantes
- Exemple : Age à partir de Date de naissance

Important

La qualité de la préparation détermine la qualité du modèle final

Vocabulaire ML : Features et Labels

Dataset d'exemple : Prédiction de prix immobilier

Surface	Chambres	Quartier	Prix
120 m ²	3	Centre	250k
80 m ²	2	Banlieue	180k


↑
Features (X)
Variables d'entrée
Caractéristiques

↑
Label (Y)
Variable cible
À prédire

Étape 3 : Division des Données

Principe

On divise les données en 2 ou 3 ensembles pour entraîner et tester le modèle




Important

Le modèle ne doit JAMAIS voir les données de test pendant l'entraînement !

Étape 4 : Choix et Entraînement du Modèle

Choisir l'algorithme

- Type de problème (classification, régression)
- Nature des données
- Taille du dataset
- Besoin d'interprétabilité
- Ressources disponibles



Entraînement

- Alimenter le modèle avec le train set
- Le modèle ajuste ses paramètres
- Optimisation itérative


Résultat

Un modèle capable de faire des prédictions sur de nouvelles données

Étape 5 : Évaluation du Modèle

Question centrale

Comment savoir si notre modèle est bon ?



Métriques selon le type de problème

- **Classification** : Accuracy, Précision, Recall, F1-Score
- **Régression** : MSE, RMSE, MAE, R^2

Les 3 Grands Types d'Apprentissage

Apprentissage Supervisé

Données étiquetées

Classification / Régression

Apprentissage Non Supervisé

Pas d'étiquettes

Clustering / Réduction dim.

Apprentissage par Renforcement

Récompenses / Punitons

Jeux / Robotique

Choix du type

Le type d'apprentissage dépend :

- De la disponibilité des labels
- De l'objectif du projet
- De la nature du problème

Apprentissage Supervisé : Principe


Definition

Apprendre à partir d'exemples étiquetés pour faire des prédictions sur de nouvelles données

Phase d'Entraînement



Phase de Prédiction



Apprentissage Supervisé : Exemples

Classification

Email Spam

- **Input** : Contenu de l'email
- **Output** : Spam ou Non
- **Données** : 10,000 emails étiquetés

Régression

Prix Immobilier

- **Input** : Surface, localisation
- **Output** : Prix en €
- **Données** : Ventes passées

Diagnostic Médical

- **Input** : Symptômes, analyses
- **Output** : Malade ou Sain
- **Données** : Dossiers médicaux


Ventes Futures

- **Input** : Historique, saison
- **Output** : Volume de ventes
- **Données** : Données historiques

Apprentissage Non Supervisé : Principe

Definition

Découvrir des structures cachées dans les données sans avoir de labels



L'algorithme découvre lui-même les structures intéressantes

Apprentissage Non Supervisé : Exemples

Clustering (Regroupement)

Segmentation Clients

- **Input** : Âge, revenu, achats
- **Output** : 4 groupes de clients
- **Usage** : Marketing ciblé

Organisation Documents

- **Input** : Textes d'articles
- **Output** : Thèmes similaires
- **Usage** : Classement automatique

Détection d'Anomalies

Fraude Bancaire

- **Input** : Transactions
- **Output** : Transactions suspectes
- **Usage** : Sécurité

Maintenance Prédictive


- **Input** : Données capteurs
- **Output** : Comportements anormaux
- **Usage** : Prévenir pannes

Overfitting vs Underfitting (1/2)

Le Défi Central du ML


Trouver le bon équilibre entre simplicité et complexité du modèle

Underfitting




Trop simple
Erreur sur
train ET test

Good Fit



Équilibré
Bonne généralisation

Overfitting



Trop complexe
Erreur élevée sur test

Overfitting vs Underfitting (2/2)

Underfitting (Sous-apprentissage)

- Modèle trop simple
- Ne capture pas les patterns
- Mauvaise performance partout

Solutions :

- Modèle plus complexe
- Plus de features
- Entraînement plus long

Overfitting (Sur-apprentissage)

- Modèle trop complexe
- Mémorise les données
- Bon sur train, mauvais sur test

Solutions :

- Plus de données
- Régularisation
- Modèle plus simple
- Cross-validation

Objectif

Créer un modèle qui **généralise** bien sur de nouvelles données

Biais et Variance : Définitions

Biais (Bias)

Erreur due à la simplicité du modèle


- Le modèle fait des hypothèses trop simplistes
- Ne capture pas la vraie relation dans les données
- **Biais élevé** → Underfitting
- **Exemple** : Utiliser une ligne droite pour des données non-linéaires

Variance

Sensibilité du modèle aux variations des données

- Le modèle apprend le bruit en plus du signal
- Très sensible aux données d'entraînement
- **Variance élevée** → Overfitting
- **Exemple** : Polynomial de degré 20 pour 10 points

Trade-off Biais-Variance 1/2



Le Trade-off

- Réduire le biais $\rightarrow$ augmente la variance
- Réduire la variance $\rightarrow$ augmente le biais
- **Objectif** : Trouver le point d'équilibre optimal

Validation Croisée (Cross-Validation) 1/2

Problème

Comment évaluer le modèle de manière robuste avec des données limitées ?

5-Fold Cross-Validation

Fold 1 :	Test	Train	Train	Train	Train
Fold 2 :	Train	Test	Train	Train	Train
Fold 3 :	Train	Train	Test	Train	Train
Fold 4 :	Train	Train	Train	Test	Train
Fold 5 :	Train	Train	Train	Train	Test

 Entraîne  Test

Validation Croisée (Cross-Validation) 2/2

Avantage

Chaque donnée sert à la fois pour l'entraînement et le test → Évaluation plus fiable

Exemple 1 : Classification d'Emails (Spam)

Le Problème

- Recevoir des milliers d'emails
- Identifier automatiquement les spams
- Éviter les faux positifs

Les Données

- 10,000 emails étiquetés
- Spam : 40%
- Non-spam (Ham) : 60%

Features Possibles

- Mots spécifiques
- Longueur du message
- Expéditeur connu/inconnu

Le Processus

- 1 Préparation
 - Nettoyage du texte
 - Extraction features
- 2 Entraînement
 - Algorithme : SVM
 - Train : 8,000 emails
- 3 Test
 - Test : 2,000 emails
 - Accuracy : 95%
- 4 Déploiement
 - Filtre automatique
 - Amélioration continue

Exemple 2 : Prédiction de Prix (Immobilier)

Le Problème

- Estimer le prix d'une maison
- Aide à la décision d'achat/vente
- Problème de régression

Les Données

- 5,000 ventes récentes
- Prix de 50k€ à 500k€

Features Utilisées

- Surface (m²)
- Nombre de chambres
- Localisation (GPS)
- Année de construction

Le Processus

1 Préparation

- Normalisation features
- Encodage localisation

2 Entraînement

- Algorithme : Régression linéaire
- Train : 4,000 maisons

3 Test

- Test : 1,000 maisons
- Erreur moyenne : $\pm 15\text{k€}$

4 Utilisation

- Input : caractéristiques maison
- Output : prix estimé

Exemple 3 : Segmentation Clients (Clustering)

Le Problème

- E-commerce avec 50,000 clients
- Besoin de groupes homogènes
- Marketing personnalisé
- Apprentissage non supervisé

Les Données

- Historique d'achats
- Comportement navigation
- Données démographiques

Features

- Montant dépensé
- Fréquence d'achat
- Catégories préférées

Le Processus

- 1 Préparation
 - Normalisation
 - Sélection features
- 2 Clustering
 - Algorithme : K-Means
 - Choix K=4 groupes
- 3 Résultats
 - Groupe 1 : VIP (5%)
 - Groupe 2 : Réguliers (35%)
 - Groupe 3 : Occasionnels (45%)
 - Groupe 4 : Inactifs (15%)
- 4 Action
 - Offres personnalisées
 - Campagnes ciblées

L'Écosystème Python pour le ML

Bibliothèques Essentielles

NumPy

Calcul numérique et tableaux multidimensionnels

Pandas

Manipulation et analyse de données tabulaires

Matplotlib / Seaborn

Visualisation et graphiques de données

Scikit-learn

Algorithmes ML classiques et preprocessing

Frameworks Deep Learning

TensorFlow

Framework Google pour la production

PyTorch

Framework Meta pour la recherche


Keras

API haut niveau pour la simplicité

Environnements de Développement

- Jupyter Notebook
- Google Colab
- VS Code / PyCharm

Workflow Typique avec Python



```
import pandas as pd  
df = pd.read_csv('data.csv')
```

```
import numpy as np  
X = np.array(df[features])
```

```
from sklearn.tree import ...  
model.fit(X_train, y_train)
```

```
import matplotlib.pyplot as plt  
plt.plot(results)
```

Les 10 Commandements du ML (1/2)

1 Commencer simple

- Baseline simple avant modèle complexe
- Régression linéaire avant deep learning

2 Comprendre les données

- Statistiques descriptives
- Visualisation exploratoire

3 Nettoyage rigoureux

- Vérifier les valeurs manquantes
- Détecter les outliers

4 Feature Engineering

- Créer des features pertinentes
- Tester différentes transformations

5 Validation appropriée

- Train/Test split
- Cross-validation

Les 10 Commandements du ML (2/2)

- 6 **Éviter l'overfitting**
 - Régularisation
 - Plus de données
- 7 **Choisir les bonnes métriques**
 - Selon le problème métier
 - Pas seulement l'accuracy
- 8 **Itérer et améliorer**
 - Tester plusieurs algorithmes
 - Optimiser les hyperparamètres
- 9 **Documenter le travail**
 - Notebooks clairs
 - Reproductibilité
- 10 **Penser au déploiement**
 - Code production-ready
 - Monitoring du modèle

Pièges Courants à Éviter

Erreurs de Données

- Data leakage (fuite)
- Features du futur
- Biais dans les données
- Déséquilibre des classes

Erreurs de Modélisation

- Overfitting
- Underfitting
- Mauvaise validation
- Ignorer les outliers

Erreurs Méthodologiques

- Tester sur les données d'entraînement
- Optimiser sur le test set
- Ignorer le contexte métier
- Features non disponibles en production

Erreurs de Communication

- Promesses irréalistes
- Ignorer les limites
- Pas d'explication du modèle

Important

La majorité des échecs ML viennent de problèmes de données, pas d'algorithmes !

Ce que nous avons appris


Concepts Fondamentaux

- Définition et principe du Machine Learning
- Différence avec programmation classique
- Le pipeline ML complet
- Types d'apprentissage (supervisé, non supervisé)

Concepts Clés

- Features et Labels
- Train/Test split
- Overfitting et Underfitting
- Validation croisée
- Biais-Variance trade-off

Le Parcours d'Apprentissage ML



Prochaine Étape : Python pour le ML

Au prochain cours

Nous allons apprendre les outils Python essentiels pour le ML :

- NumPy : manipulation de tableaux
- Pandas : analyse de données
- Matplotlib : visualisation
- Scikit-learn : premiers modèles ML

Ressources recommandées

- Installer Anaconda (Python + libraries)
- Créer un compte Google Colab (gratuit)
- Explorer Kaggle pour des datasets