



Clustering

Malek Bouzaïen

Année universitaire: 2025 - 2026

Qu'est-ce que le Clustering ?



Définition Simple

Clustering = Regroupement

Diviser des données en groupes où les points se ressemblent

Objectif :


- Points dans un même groupe → **similaires**
- Points de groupes différents → **différents**

Pas de labels !

L'algorithme découvre lui-même les groupes cachés dans les données

K-Means : L'Algorithme Principal

ALGORITHME K-MEANS



Comment fonctionne K-Means ?

Principe

K-Means trouve K groupes en plaçant des centres


Les 4 étapes :

- 1 Choisir K (nombre de groupes souhaité)
- 2 Placer K centres au hasard
- 3 Attribuer chaque point au centre le plus proche
- 4 Répéter jusqu'à ce que les centres ne bougent plus

Exemple

Pour segmenter des clients : $K=3 \rightarrow$ groupe Budget, Moyen, Premium

Comment Choisir K ?



Problème

K-Means a besoin de connaître K à l'avance. Comment le choisir ?

Solution : Chercher le "coude"




- Tester plusieurs valeurs de K (1, 2, 3, ..., 10)
- Mesurer la qualité pour chaque K
- Le graphique forme un "coude"
- Le coude indique le K optimal

Règle

Choisir K au niveau du coude = bon compromis !

Les 3 Algorithmes de Clustering

COMPARAISON DES 3 ALGORITHMES






Comparaison des 3 Algorithmes

Algorithme	Avantage	Usage
K-Means	Rapide et simple	Groupe ronds
Hiérarchique	Pas besoin de K	Petits datasets
DBSCAN	Formes complexes	Bruit/Outliers

Lequel choisir ?

- **K-Means** : La plupart du temps (rapide, efficace)
- **Hiérarchique** : Quand on ne connaît pas K
- **DBSCAN** : Formes irrégulières ou présence de bruit

APPLICATIONS DU CLUSTERING



ET BIEN PLUS...

AUTRES APPLICATIONS

- Compression images (réduire couleurs)
- Recommandations (clients similaires)
 - Biologie (groupes de gènes)
- Réseaux sociaux (communautés)

Domaine	Application
Marketing	Segmentation clients
E-commerce	Recommandations produits
Documents	Organisation par thème
Sécurité	Détection d'anomalies
Images	Compression (réduire couleurs)
Biologie	Groupe de gènes
Réseaux sociaux	Communautés

Cas typique

Une entreprise avec 10000 clients → 4 segments pour marketing ciblé

Comment Faire du Clustering? (5 étapes)

- 1 **Collecter** les données
- 2 **Normaliser** (mettre à la même échelle)
- 3 **Choisir K** (méthode du coude)
- 4 **Appliquer K-Means**
- 5 **Interpréter** les groupes

Le plus important

L'interprétation ! Les groupes doivent avoir du sens pour votre domaine.

Points Clés à Retenir

1. Apprentissage NON Supervisé

Pas de labels → on découvre des structures cachées

2. K-Means = L'algorithme principal

Rapide, simple, efficace pour la plupart des cas

3. Méthode du coude

Pour trouver le bon nombre de groupes (K)

4. Normaliser les données

TOUJOURS mettre les features à la même échelle

5. Applications partout

Marketing, documents, anomalies, compression, etc.

Le Clustering c'est :

- Trouver des groupes dans des données non étiquetées
- K-Means : l'outil principal (rapide et efficace)
- Méthode du coude : pour choisir K
- Applications nombreuses : clients, documents, etc.

L'essentiel

Le clustering révèle des structures cachées pour mieux comprendre vos données